

Día 2: Modelación de la mortalidad y descomposición de la esperanza de vida

José Manuel Aburto y Ana Cristina Gómez Ugarte Valerio

2025-12-31

Tabla de contenidos

1. Preparación de datos	1
Opción 1: descargar directamente desde HMD	2
Opción 2: cargar desde el archivo local	2
2. Modelación de la mortalidad	4
2.1 Modelo de Gompertz	5
2.2 Modelo de Weibull	7
2.3 Modelo de Heligman-Pollard	10
3. Descomposición de la esperanza de vida	13
3.1 Cargar los datos	13
3.2 Cargar la función de tabla de vida	15
3.3 Construir tablas de vida para cada año	16
3.4 Descomposición por edad: método de Arriaga	17
3.5 Extensión: descomposición por edad y causa	19

En esta práctica trabajaremos con dos tareas:

1. Ajustar modelos de mortalidad: Gompertz, Weibull y Heligman-Pollard.
2. Descomponer cambios en esperanza de vida por edad y causa de muerte.

1. Preparación de datos

Usaremos datos de mortalidad de la [Human Mortality Database](#) (HMD). La HMD ofrece tablas de vida comparables para muchos países.

Opción 1: descargar directamente desde HMD

Si quieren explorar países además de Estados Unidos, pueden descargar datos directamente desde HMD después de registrarse gratuitamente en <https://www.mortality.org/>.

```
# Cargar paquetes
library(tidyverse)
library(HMDHFDplus)
library(MortalityLaws)
library(reshape2)

# Definir credenciales de HMD
myHMDusername <- "your_email@example.com"
myHMDpassword <- "your_password"

# Descargar datos de tabla de vida desde HMD
LT <- readHMDweb(
  CNTRY = "USA",
  item = "fltper_1x1",
  username = myHMDusername,
  password = myHMDpassword
)
```

Opción 2: cargar desde el archivo local

Para esta práctica ya tenemos descargada una tabla de vida femenina de Estados Unidos.

```
# Cargar paquetes
library(tidyverse)
library(HMDHFDplus)
library(MortalityLaws)
library(reshape2)
options(scipen = 4) # Evitar notacion cientifica
```

```
# Código del país
country_code <- "USA"


# Leer archivo local de HMD
data_path <- "USAfltper_1x1.txt"
LT <- readHMD(data_path, fixup = TRUE)
```

```
# Revisar la estructura inicial
head(LT)
```

	Year	Age	mx	qx	ax	lx	dx	Lx	Tx	ex	OpenInterval
1	1933	0	0.05418	0.05208	0.26	100000	5208	96130	6279695	62.80	FALSE
2	1933	1	0.00887	0.00883	0.50	94792	837	94374	6183565	65.23	FALSE
3	1933	2	0.00402	0.00402	0.50	93955	377	93767	6089191	64.81	FALSE
4	1933	3	0.00287	0.00287	0.50	93578	268	93444	5995425	64.07	FALSE
5	1933	4	0.00223	0.00223	0.50	93310	208	93206	5901981	63.25	FALSE
6	1933	5	0.00185	0.00185	0.50	93102	172	93016	5808775	62.39	FALSE

Veamos cómo han evolucionado los patrones de mortalidad desde el inicio de la serie temporal (1933).

```
ggplot(data = LT) +
  geom_line(aes(x = Age, y = mx, colour = Year, group = Year)) +
  scale_y_log10() +
  scale_color_viridis_c() +
  labs(
    title = paste("Tasas de mortalidad por edad:", country_code, "mujeres"),
    x = "Edad",
    y = "Tasa de mortalidad (escala log)"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(face = "bold"),
    legend.position = "right"
  )
```



Pregunta: ¿Cómo han cambiado el nivel general y la forma de la curva de mortalidad a lo largo del tiempo?

2. Modelación de la mortalidad

Ajustaremos tres modelos paramétricos a la mortalidad femenina de Estados Unidos en **1990**. Cada modelo captura una parte distinta de la curva de mortalidad por edad:

- **2.1 Gompertz:** aumento exponencial de la mortalidad adulta (edades 30+).
- **2.2 Weibull:** descenso del riesgo en infancia y niñez (edades 1-10).
- **2.3 Heligman-Pollard:** rango completo de edades, combinando tres componentes.

```
# Seleccionar año para el análisis
year <- 1990

# Filtrar datos de ese año
LT_year <- LT %>%
  filter(Year == year)
```

2.1 Modelo de Gompertz

El **modelo de Gompertz** es uno de los modelos paramétricos de mortalidad más simples y utilizados. Describe la mortalidad adulta como un aumento exponencial:

$$\mu_x = a \cdot e^{bx}$$

donde μ_x es la fuerza de mortalidad a la edad x , a es el nivel basal de mortalidad y b es la tasa de envejecimiento.

Este modelo funciona mejor para edades 30+, donde la mortalidad aumenta de forma casi exponencial. No puede capturar bien los patrones de edades tempranas, como mortalidad infantil/juvenil o el aumento por accidentes en edades jóvenes.

```
# Preparar datos, edades 30-100
gompertz_data <- LT_year %>%
  filter(Age >= 30, Age <= 100)

# Ajustar modelo de Gompertz
gomp_fit <- MortalityLaw(
  x = gompertz_data$Age,
  mx = gompertz_data$mx,
  law = "gompertz",
  opt.method = "poissonL"
)

# Mostrar parametros
summary(gomp_fit)
```

Gompertz model: $\mu[x] = A \exp[Bx]$

Fitted values: mx

Call: MortalityLaw(x = gompertz_data\$Age, mx = gompertz_data\$mx, law = "gompertz",
opt.method = "poissonL")

Deviance Residuals:

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.0148	-0.0012	0.0002	0.0000	0.0004	0.0115

Parameters:

A	B
0.0004	0.0951

Goodness of fit:


logLik	AIC	BIC
2.4898	-0.9797	3.5457

Residual standard error: 0.02822 on 69 degrees of freedom

```
# Predecir en todo el rango de edad
ages_full <- 0:110
gompertz_pred <- predict(gomp_fit, x = ages_full)

# Graficar observado vs ajustado
obs <- LT_year %>% select(Age, mx)
pred <- tibble(Age = ages_full, mx = gompertz_pred)

ggplot() +
  geom_point(
    data = obs, aes(x = Age, y = mx, color = "Observado"),
    size = 1.5, alpha = 0.8
  ) +
  geom_line(
    data = pred, aes(x = Age, y = mx, color = "Gompertz"),
    linewidth = 1.2
  ) +
  scale_y_log10() +
  scale_color_manual(values = c("Observado" = "black", "Gompertz" = "blue")) +
  labs(
    title = paste("Ajuste del modelo de Gompertz:", country_code, year, "mujeres"),
    x = "Edad",
    y = "Tasa de mortalidad (escala log)",
    color = NULL
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(face = "bold"),
    legend.position = "bottom"
  )
```



Preguntas:

- Interpreten los parámetros estimados.
- ¿En qué rango de edades ajusta bien el modelo y dónde empieza a fallar?

2.2 Modelo de Weibull

El **modelo de Weibull** captura la fase decreciente de la mortalidad en la infancia y niñez. Su función de riesgo es:

$$\mu_x = \frac{k}{\lambda} \left(\frac{x}{\lambda} \right)^{k-1}$$

donde k es el **parámetro de forma** y λ es el **parámetro de escala**.

El parámetro de forma k determina la dirección del riesgo con la edad:

- $k < 1$: riesgo decreciente, característico de la mortalidad infantil y de la niñez.
- $k = 1$: riesgo constante (distribución exponencial).
- $k > 1$: riesgo creciente, como en procesos similares a Gompertz.

Para mortalidad infantil y de la niñez esperamos $k < 1$: una persona recién nacida enfrenta un riesgo inicial alto que cae rápidamente durante los primeros años de vida. Por eso Weibull complementa a Gompertz: juntos cubren dos segmentos monotónicos de la curva de mortalidad humana.

```
# Preparar datos, edades 1-10
weibull_data <- LT_year %>%
  filter(Age >= 1, Age <= 10)

# Ajustar modelo de Weibull
weibull_fit <- MortalityLaw(
  x = weibull_data$Age,
  mx = weibull_data$mx,
  law = "weibull",
  opt.method = "poissonL"
)

# Mostrar parametros
summary(weibull_fit)
```

Weibull model: $\mu[x] = 1/\sigma * (x/M)^{(M/\sigma - 1)}$

Fitted values: mx

Call: MortalityLaw(x = weibull_data\$Age, mx = weibull_data\$mx, law = "weibull",
opt.method = "poissonL")

Deviance Residuals:

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.0002	0.0000	0.0000	0.0000	0.0001	0.0001

Parameters:

sigma	M
34.8775	0.0323

Goodness of fit:

logLik	AIC	BIC
-3.6968	11.3936	11.9987

Residual standard error: 0.0002897 on 8 degrees of freedom



```

# Predecir para edades 1-10
ages_early <- 1:10
weibull_pred <- predict(weibull_fit, x = ages_early)

# Graficar observado vs ajustado
pred <- tibble(Age = ages_early, mx = weibull_pred)

ggplot() +
  geom_point(
    data = LT_year, aes(x = Age, y = mx, color = "Observado"),
    size = 1.5, alpha = 0.8
  ) +
  geom_line(
    data = pred, aes(x = Age, y = mx, color = "Weibull"),
    linewidth = 1.2
  ) +
  scale_y_log10() +
  scale_color_manual(values = c("Observado" = "black", "Weibull" = "green")) +
  labs(
    title = paste("Modelo de Weibull:", country_code, year, "mujeres"),
    x      = "Edad",
    y      = "Tasa de mortalidad (escala log)",
    color = NULL
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title      = element_text(face = "bold"),
    legend.position = "bottom"
  )

```



Preguntas:

- Interpreten los parámetros estimados.
- ¿Por qué excluimos la edad 0 del ajuste?

2.3 Modelo de Heligman-Pollard

El modelo de **Heligman-Pollard** (1980) extiende la lógica de Gompertz para capturar patrones de mortalidad en **todas las edades**. Descompone la mortalidad en tres componentes con interpretación demográfica:

$$\frac{q_x}{p_x} = \underbrace{A(x+B)^C}_{(1) \text{ infancia}} + \underbrace{D \exp\left[-E\left(\ln \frac{x}{F}\right)^2\right]}_{(2) \text{ joroba de accidentes}} + \underbrace{GH^x}_{(3) \text{ senescencia}}$$

- **Componente 1** $A(x+B)^C$: captura el descenso rápido de la mortalidad infantil y de la niñez (edades 0-10).
- **Componente 2** $D \exp[-E(\ln(x/F))^2]$: captura la joroba de accidentes en adultos jóvenes (edades aproximadas 15-35), como una campana en la escala logarítmica de la edad centrada alrededor de F .
- **Componente 3** GH^x : captura el aumento exponencial de la mortalidad en edades avanzadas.

El modelo tiene **8 parámetros** (A, B, C, D, E, F, G, H) y se ajusta sobre el rango completo de edades (0-100).

```
# Preparar datos, edades 0-100
hp_data <- LT_year %>%
  filter(Age >= 0, Age <= 100)

# Ajustar modelo de Heligman-Pollard
hp_fit <- MortalityLaw(
  x = hp_data$Age,
  mx = hp_data$mx,
  law = "HP",
  opt.method = "poissonL"
)

# Mostrar parametros
summary(hp_fit)
```

Heligman-Pollard model: $q[x]/p[x] = A^[(x + B)^C] + D \exp[-E \log(x/F)^2] + G H^x$
Fitted values: mx

Call: MortalityLaw(x = hp_data\$Age, mx = hp_data\$mx, law = "HP", opt.method = "poissonL")

Deviance Residuals:

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-0.0048	-0.0002	0.0000	0.0000	0.0001	0.0063

Parameters:

A	B	C	D	E	F_
4.000000e-04	0.000000e+00	1.340000e-02	1.868885e+26	5.320000e-02	1.131747e+17
G	H				
0.000000e+00	1.136400e+00				

Goodness of fit:

logLik	AIC	BIC
2.5021	10.9958	31.9167

Residual standard error: 0.01191 on 93 degrees of freedom


```
# Predecir en todo el rango de edad
hp_pred <- predict(hp_fit, x = ages_full)
```

Ahora que los tres modelos están ajustados, los comparamos en el **rango completo de edades**.

```
# Construir bases de prediccion separadas para cada modelo
gomp_df <- tibble(Age = ages_full, mx = gompertz_pred)
weib_df <- tibble(Age = ages_early, mx = weibull_pred)
hp_df <- tibble(Age = ages_full, mx = hp_pred)

ggplot() +
  geom_point(
    data = LT_year, aes(x = Age, y = mx, color = "Observado"),
    size = 1.5, alpha = 0.8
  ) +
  geom_line(
    data = gomp_df, aes(x = Age, y = mx, color = "Gompertz"),
    linewidth = 1.2
  ) +
  geom_line(
    data = weib_df, aes(x = Age, y = mx, color = "Weibull"),
    linewidth = 1.2
  ) +
  geom_line(
    data = hp_df, aes(x = Age, y = mx, color = "Heligman-Pollard"),
    linewidth = 1.2
  ) +
  scale_y_log10() +
  scale_color_manual(
    values = c(
      "Observado"      = "black",
      "Gompertz"       = "blue",
      "Weibull"        = "green",
      "Heligman-Pollard" = "red"
    ),
    breaks = c("Observado", "Gompertz", "Weibull", "Heligman-Pollard")
  ) +
  labs(
    title = paste("Comparacion de tres modelos:", country_code, year, "mujeres"),
    x      = "Edad",
    y      = "Tasa de mortalidad (escala log)",
    color = NULL
  ) +
  theme_minimal(base_size = 12) +
  theme(
```

```
plot.title      = element_text(face = "bold"),
legend.position = "bottom"
)
```



Preguntas:

- ¿Pueden identificar los tres componentes de la curva de Heligman-Pollard en la gráfica?
- ¿En qué rangos de edad funciona mejor cada modelo y dónde falla?

3. Descomposición de la esperanza de vida

La esperanza de vida cambia de forma importante a lo largo del tiempo. Queremos entender **qué grupos de edad** contribuyeron más a ese cambio. Usaremos datos de hombres en Venezuela en 1996 y 2013 para ilustrar el método de descomposición de Arriaga.

3.1 Cargar los datos

Los datos corresponden a hombres en Venezuela en 1996 y 2013.

```
# Cargar datos de mortalidad masculina en Venezuela, 1996 y 2013
load(file = "mortality-modeling-decomposition-data.RData")
```

El objeto `age.specific.mx` contiene tasas de mortalidad específicas por edad.

```
head(age.specific.mx)
```

	sex	year	age	mx
1	1	1996	0	0.0245173704
2	1	1996	1	0.0015086759
3	1	1996	5	0.0004879040
4	1	1996	10	0.0005411554
5	1	1996	15	0.0019348848
6	1	1996	20	0.0027889940

El objeto `cause.age.specific.mx` contiene tasas de mortalidad específicas por edad y causa.
Las columnas 1:10 corresponden a:

1. Enfermedades circulatorias
2. Neoplasias
3. Diabetes
4. Homicidio y otras causas violentas
5. Otras causas externas
6. Condiciones del periodo perinatal
7. Enfermedades respiratorias
8. Enfermedades infecciosas
9. Enfermedades digestivas
10. Otras causas

```
head(cause.age.specific.mx)
```

	1	2	3	4	5	
1	0.00011127943	0.00003948625	0.0000107689767	0.00026922442	0.00011845874	
2	0.00002378115	0.00008180714	0.0000028537375	0.00004946478	0.00009892957	
3	0.00001715870	0.00004252374	0.0000007460306	0.00007311100	0.00012085695	
4	0.00001397350	0.00002286572	0.0000010162543	0.00029039467	0.00010137137	
5	0.00006243906	0.00005880888	0.0000094384625	0.00103895691	0.00042618289	
6	0.00013684845	0.00010744300	0.0000282744729	0.00117621807	0.00065483679	
	6	7	8	9	10	sex
1	0.0117130570253	0.00180918809	0.004587584088	0.000215379535	0.00564294381	1
2	0.0000000000000	0.00021212782	0.000390010788	0.000025683637	0.00062401726	1
3	0.0000007460306	0.00002238092	0.000024619009	0.000008206336	0.00017755528	1
4	0.0000000000000	0.00001143286	0.000009146289	0.000005335335	0.00008561942	1
5	0.0000000000000	0.00003484971	0.000053726633	0.000029767459	0.00022071482	1

```

6 0.00000000000000 0.00007012069 0.000222802847 0.000048632093 0.00034381759 1
  year age
1 1996  0
2 1996  1
3 1996  5
4 1996 10
5 1996 15
6 1996 20

```

3.2 Cargar la función de tabla de vida

Para descomponer la diferencia entre esperanzas de vida necesitamos construir tablas de vida a partir de las tasas de mortalidad en `age.specific.mx`. El archivo `funciones-dia-02.R` contiene una función de tabla de vida y etiquetas útiles para las gráficas.

```

# Cargar la funcion de tabla de vida
source("funciones-dia-02.R")

```

Podemos revisar nuestra función de tabla de vida:

```
LifeTable_function
```

```

function (nmx = mx, age = c(0, 1, seq(5, 85, 5)), nax = NULL)
{
  n <- c(diff(age), 999)
  if (is.null(nax)) {
    nax <- 0.5 * n
  }
  nqx <- (n * nmx)/(1 + (n - nax) * nmx)
  nqx <- c(nqx[-length(nqx)], 1)
  nqx[nqx > 1] <- 1
  npx <- 1 - nqx
  lx <- cumprod(c(1, npx))
  ndx <- -diff(lx)
  lxpn <- lx[-1]
  nLxpn <- n * lxpn + ndx * nax
  nLx <- c(nLxpn[-length(nLxpn)], lxpn[length(lxpn) - 1]/nmx[length(nmx)])
  Tx <- rev(cumsum(rev(nLx)))
  lx <- lx[1:length(age)]
  ex <- Tx/lx
  data.frame(cbind(nmx, age, nax, npx, lx, nLx, Tx, ex))
}

```

Los parámetros principales son:

- **nmx**: vector de tasas de mortalidad, usualmente aproximadas con defunciones / población a mitad de año.
- **age**: vector con la edad inferior del grupo de edad.
- **nax**: vector con valores de **nax**. Si no se provee, asignamos la mitad de la longitud del intervalo.

3.3 Construir tablas de vida para cada año

```
lifetable.1996 <- LifeTable_function(
  nmx = age.specific.mx[age.specific.mx$year %in% 1996, ]$mx,
  age = age.specific.mx[age.specific.mx$year %in% 1996, ]$age
)

head(lifetable.1996)
```

	nmx	age	nax	npx	lx	nLx	Tx	ex
1	0.0245173704	0	0.5	0.9757795	1.0000000	0.9878898	69.33658	69.33658
2	0.0015086759	1	2.0	0.9939835	0.9757795	3.8913765	68.34869	70.04522
3	0.0004879040	5	2.5	0.9975635	0.9699087	4.8436355	64.45732	66.45710
4	0.0005411554	10	2.5	0.9972979	0.9675455	4.8311914	59.61368	61.61331
5	0.0019348848	15	2.5	0.9903721	0.9649311	4.8014298	54.78249	56.77348
6	0.0027889940	20	2.5	0.9861516	0.9556408	4.7451190	49.98106	52.30109

```
lifetable.2013 <- LifeTable_function(
  nmx = age.specific.mx[age.specific.mx$year %in% 2013, ]$mx,
  age = age.specific.mx[age.specific.mx$year %in% 2013, ]$age
)

head(lifetable.2013)
```

	nmx	age	nax	npx	lx	nLx	Tx	ex
1	0.0165565677	0	0.5	0.9835794	1.0000000	0.9917897	70.99212	70.99212
2	0.0006254993	1	2.0	0.9975011	0.9835794	3.9294018	70.00033	71.16897
3	0.0003114802	5	2.5	0.9984438	0.9811215	4.9017906	66.07093	67.34224
4	0.0004158072	10	2.5	0.9979231	0.9795947	4.8928873	61.16914	62.44331
5	0.0030976117	15	2.5	0.9846310	0.9775602	4.8502407	56.27625	57.56806
6	0.0049095345	20	2.5	0.9757500	0.9625361	4.7543265	51.42601	53.42762

La esperanza de vida al nacer en 1996 y 2013 fue:

```
lifetable.1996$ex[1]
```

```
[1] 69.33658
```

```
lifetable.2013$ex[1]
```

```
[1] 70.99212
```

```
# Diferencia en esperanza de vida
big.delta <- lifetable.2013$ex[1] - lifetable.1996$ex[1]

big.delta
```

```
[1] 1.655535
```

3.4 Descomposición por edad: método de Arriaga

Seguimos el algoritmo descrito en Arriaga (1984):

$${}_n\Delta_x = \frac{\ell_x^1}{\ell_0^1} \left(\frac{{}_nL_x^2}{\ell_x^2} - \frac{{}_nL_x^1}{\ell_x^1} \right) + \frac{T_{x+n}^2}{\ell_0^1} \left(\frac{\ell_x^1}{\ell_x^2} - \frac{\ell_{x+n}^1}{\ell_{x+n}^2} \right)$$

Paso 1: obtener la información necesaria de las tablas de vida

```
# Extraer componentes de la tabla de vida
l1 <- lifetable.1996$lx
l2 <- lifetable.2013$lx

L1 <- lifetable.1996$Lx
L2 <- lifetable.2013$Lx

T1 <- lifetable.1996$Tx
T2 <- lifetable.2013$Tx

LAG <- length(l1)
```

Paso 2: calcular componentes directos e indirectos

```
DE <- (l1 / l1[1]) * ((L2 / l2) - (L1 / l1))

IE <- (T2[-1] / l1[1]) * ((l1[-LAG] / l2[-LAG]) - (l1[-1] / l2[-1]))

# Agregar 0: no hay efecto indirecto para el ultimo grupo de edad
IE <- c(IE, 0)
```

Paso 3: sumar los componentes para obtener la contribución específica por edad y verificar contra el cambio total

```
# Sumar efectos directos e indirectos
ALL <- DE + IE

# Verificacion: la suma debe ser igual a big.delta
big.delta
```

```
[1] 1.655535
```


```
# Suma de contribuciones especificas por edad
sum(ALL)
```

```
[1] 1.655535
```

Paso 4: graficar e interpretar resultados

```
ggplot() +
  geom_bar(
    aes(
      x = factor(c(0, 1, seq(5, 85, 5)), labels = age_names),
      y = ALL,
      fill = ALL > 0
    ),
    stat = "identity"
  ) +
  scale_fill_manual(
    values = c("TRUE" = "steelblue", "FALSE" = "tomato"),
    labels = c("TRUE" = "Positiva", "FALSE" = "Negativa"),
    name = NULL
  ) +
  scale_x_discrete(guide = guide_axis(n.dodge = 2)) +
```

```
labs(
  title = bquote("Cambio en" ~ e[0] ~ "(hombres, Venezuela, 1996-2013)"),
  x     = "Grupo de edad",
  y     = "Contribucion al cambio en esperanza de vida (años)"
) +
theme_minimal(base_size = 12) +
theme(
  plot.title      = element_text(face = "bold"),
  legend.position = "bottom"
)
```



Preguntas:

- ¿Qué grupos de edad contribuyeron más al aumento o descenso de la esperanza de vida?
- ¿Qué revelan estos patrones sobre las tendencias de mortalidad en Venezuela entre 1996 y 2013?

3.5 Extensión: descomposición por edad y causa

Para extender la descomposición a causas de muerte, recordemos la ecuación de las diapositivas:

$${}_n\Delta_x^i = {}_n\Delta_x \frac{{}_nm_{x,i}^2 - {}_nm_{x,i}^1}{{}_nm_x^2 - {}_nm_x^1}$$

El primer elemento, ${}_n\Delta_x$, ya lo tenemos en el objeto **ALL** y fue graficado arriba. El denominador es simplemente la diferencia de tasas de mortalidad específicas por edad:

```
# Cambio en tasas de mortalidad especificas por edad (denominador)
denominator <- lifetable.2013$nmx - lifetable.1996$nmx
```

Ahora necesitamos la diferencia entre la mortalidad específica por edad y causa en los dos periodos. Esta información está en el objeto **cause.age.specific.mx**. Podemos hacer esta operación usando matrices.

```
# Cambio en tasas de mortalidad especificas por edad y causa (numerador)
matrix.2013 <- cause.age.specific.mx[cause.age.specific.mx$year %in% 2013, 1:10]
matrix.1996 <- cause.age.specific.mx[cause.age.specific.mx$year %in% 1996, 1:10]
numerator <- matrix.2013 - matrix.1996
```

Ahora tenemos todos los ingredientes para calcular la descomposición por edad y causa:

```
age.cause.decomposition <- ALL * (numerator / denominator)

# Renombrar columnas
colnames(age.cause.decomposition) <- cause_names

# Agregar columna de grupo de edad
age.cause.decomposition$age.group <- factor(c(0, 1, seq(5, 85, 5)), labels = age_names)

# Convertir a formato largo
age.cause.decomposition.long <- melt(
  data = age.cause.decomposition,
  id.vars = "age.group",
  variable.name = "Causa",
  value.name = "Contribucion"
)


head(age.cause.decomposition.long)
```

	age.group	Causa	Contribucion
1	0	Enfermedades circulatorias	0.0042980914
2	1-4	Enfermedades circulatorias	0.0042811748

3	5-9	Enfermedades circulatorias	0.0040094764
4	10-14	Enfermedades circulatorias	0.0029646728
5	15-19	Enfermedades circulatorias	0.0046117807
6	20-24	Enfermedades circulatorias	-0.0008786136

Finalmente, grafiquemos los resultados:

```
ggplot(
  data = age.cause.decomposition.long,
  aes(x = age.group, y = Contribucion, fill = Causa)
) +
  geom_bar(stat = "identity", position = "stack") +
  scale_x_discrete(guide = guide_axis(n.dodge = 2)) +
  labs(
    title = bquote("Cambio en" ~ e[0] ~ "(hombres, Venezuela, 1996-2013)"),
    x      = "Grupo de edad",
    y      = "Contribucion al cambio en esperanza de vida (años)",
    fill   = "Causa de muerte"
  ) +
  theme_minimal(base_size = 12) +
  theme(
    plot.title      = element_text(face = "bold"),
    legend.position = "right"
  )
)
```



Pregunta: ¿Qué causas de muerte impulsaron el descenso en la esperanza de vida y en qué edades tuvieron mayor impacto?